

Do FASTQ à Taxonomia

Pipeline completo de análise de 16S rRNA

Mariana Feitosa Cavaleiro
22/04/2026

PARTE 1

Ponto de partida

FASTQ e controle de qualidade

O que é Bioinformática?

A ciência que une **Biologia**, **Computação** e **Estatística** para interpretar dados biológicos em larga escala.



Origem

Surgiu da necessidade de analisar genomas inteiros.



Interdisciplinar

Não é 'apenas programação':
exige entendimento biológico profundo.



Aplicações

Ferramenta essencial em
genômica, metagenômica e
proteômica.

Por que a Bioinformática é essencial?



Volume Massivo

Um sequenciador Illumina gera ~600 GB de dados por corrida.



Análise Inviável

É impossível analisar manualmente milhões de sequências.



Algoritmos

Precisamos de filtros para ruído, alinhamento e classificação.



Reprodutibilidade

A ciência depende de pipelines documentados e replicáveis.

Sequenciamento de Nova Geração (NGS)

Tecnologia que permite sequenciar **milhões de fragmentos de DNA** simultaneamente, em paralelo.



Conceito

Chamado de 'massively parallel sequencing'.



Plataformas

Illumina (short), Nanopore (long) e PacBio (HiFi).



Custo-Efetivo

De US\$100M (2001) para ~US\$200 (2024) por genoma.

Do DNA ao Arquivo Digital

Fluxo de Trabalho:

1. Extração do DNA da amostra biológica
2. Fragmentação e preparação da biblioteca
3. Sequenciamento na plataforma (ex: Illumina MiSeq)
4. **Base calling:** conversão de sinais luminosos em bases (A, T, C, G)
5. Geração do arquivo **FASTQ** — nosso ponto de partida!

Anatomia do FASTQ (Exemplo):

```
# Linha 1: Identificador (@)
@M00123:45:000000000-ABC12:1:1101:15234:1568

# Linha 2: Sequência Bruta
GATCGATCGATCGATCAATCGATCGATCGATCGATCAATCG

# Linha 3: Separador (+)
+

# Linha 4: Scores de Qualidade (Phred)
!''*((**++))%%%++)(%%%)!1***-+*')**)55CCF
```

O que é formato FASTQ?

Um arquivo de texto simples que armazena tanto a sequência de nucleotídeos quanto a qualidade de cada base chamada.

- Evolução do formato FASTA (que não tinha informação de qualidade)
- Padrão universal aceito por todas as plataformas de sequenciamento
- Extensões comuns: .fastq, .fq, .fastq.gz (comprimido)

Comparativo: FASTA vs. FASTQ

Formato FASTA

- 2 linhas por registro
- Apenas a sequência
- Uso: Genomas de referência

Exemplo:

```
>Seq ID 001  
GATCGATCGATCGATC...
```

Formato FASTQ

- 4 linhas por registro
- Sequência + Qualidade (Phred)
- Uso: Dados brutos (NGS)

Exemplo:

```
@M00123:45:ABC12...  
GATCGATCGATCGATC...  
+  
! '* ( ( ( ** + ) ) % % % ++
```


Anatomia do FASTQ: As 4 Linhas

Cada leitura (read) ocupa exatamente 4 linhas

Linha 1 (@)

Identificador Único

Contém metadados sobre a leitura e o equipamento.

Linha 2

Sequência Bruta

Bases nitrogenadas (A, G, T, C) chamadas pelo sequenciador.

Linha 3 (+)

Separador

Pode ser um simples '+' ou repetir o identificador da Linha 1.

Linha 4

Scores de Qualidade

Qualidade de cada base (Phred) codificada em caracteres ASCII.

Decodificando o Header

Cada campo carrega informação sobre a origem física da leitura

```
@M00123:45:000000000-ABC12:1:1101:15234:1568 1:N:0:ATCACG
```

@M00123

Identificador do instrumento

MiSeq nº 123

:45 & :000000000-ABC12

Número da Corrida e Flowcell

Identificação única do lote de sequenciamento

:1:1101

Localização Física

Lane 1, Tile 1101

:15234:1568

Coordenadas X:Y

Posição exata dentro do tile

1:N:0:ATCACG

Status e Multiplex

Read 1, não filtrado, controle 0, índice

Linha 2: A Sequência

GATCGATCGATCGATCAATCGATCGATCGATCGATCAATCG

A sequência bruta de nucleotídeos

- **A, T, C, G:** Adenina, Timina, Citosina e Guanina.
- **N:** Base indeterminada (quando o sequenciador não consegue identificar).
- Representa a leitura direta da molécula de DNA pelo equipamento.

Sobre a Sequência Bruta

Composição da Sequência

Cada caractere representa um nucleotídeo chamado pelo sequenciador.

'N': Indica que o sequenciador não conseguiu determinar a base.


Variabilidade de Comprimento

- **Illumina (Short read):** ~150 bp
- **Nanopore:** >10.000 bp

Reads Paired-end

Utiliza dois arquivos (**R1 e R2**) contendo leituras complementares da mesma molécula de DNA.

Linha 3: O Separador (+)



+

Função e Características

Simplesmente um '+' que separa a sequência (Linha 2) dos scores de qualidade (Linha 4).

- **Identificador Opcional:** Pode opcionalmente repetir o identificador da Linha 1.
- **Uso Prático:** Na prática, quase sempre é apenas o caractere '+'.
- **Legado:** Existe por razões históricas de parsing do formato FASTQ.

```
! ' ' * ( ( ( * * * + ) ) % % % + + ) ( % % % % ) . 1 * * * - + * ' ' ) ) * * 5 5 C C F
```

Linha 4: Os Scores de Qualidade

Cada caractere ASCII nesta linha traduz numericamente a probabilidade de erro para a base correspondente na sequência (Linha 2).



Representa a **confiança** da chamada de cada base.



Usa a escala Phred codificada em caracteres de texto único (ASCII).

O que é o Phred Quality Score?

$$Q = -10 \times \log_{10}(P)$$

Onde **P** é a probabilidade de erro na chamada da base.



Origem: Desenvolvido no Projeto Genoma Humano (programa phred)



Relação de Confiança: Quanto MAIOR o Q, MENOR a probabilidade de erro



Padrão: É a métrica universal de confiança em sequenciamento

Tabela de referência: Phred scores

Score (Q)	Prob. Erro	Precisão	Significado
Q10	1 em 10	90%	Baixa qualidade
Q20	1 em 100	99%	Aceitável
Q30	1 em 1.000	99.9%	Alta qualidade
Q40	1 em 10.000	99.99%	Excelente

Exemplo Prático: Lendo a Qualidade

```
Seq: G A T C G A T C
Qual: I I 5 ! I I ( I
Q: 40 40 20 0 40 40 7 40
```



Ponto de Atenção: Baixa Qualidade

Note que a 4ª base (C) tem **Q=0**: o sequenciador não tem confiança nessa chamada, indicando uma probabilidade máxima de erro.

FastQC: Controle de Qualidade

Software que gera um relatório visual completo sobre a qualidade de um arquivo FASTQ.



Origem

Desenvolvido pelo Babraham Institute no Reino Unido.



Desempenho

Analisa milhões de reads em apenas alguns minutos.



Interface Visual

- Verde (Bom)
- Amarelo (Atenção)
- Vermelho (Falha)

Gráficos intuitivos baseados em semáforos.

Executando o FastQC

```
# Instalação via conda:  
conda install -c bioconda fastqc  
  
# Execução básica:  
fastqc amostra_R1.fastq.gz amostra_R2.fastq.gz  
  
# Saída: amostra_R1_fastqc.html (relatório visual)
```

O relatório HTML pode ser aberto em qualquer navegador.

Módulos do FastQC (Parte 1)

Per Base Sequence Quality

Box-plot de Q por posição. Espera-se $Q > 28$.

Queda em 3' é normal, mas deve ser tratada.

Per Sequence Quality

Distribuição geral de Q.

Alvo: Pico em $Q \geq 30$

Sequence Content

Proporção de A/T/C/G.

Linhas paralelas e estáveis. Desvio inicial é normal para 16S.

Duplication Levels

Frequência de reads repetidos.

Alta duplicação: pode indicar baixa complexidade da biblioteca.

Adapter Content

Contaminação por sequências de adaptadores.

Curvas subindo = Adaptadores presentes (Trimming obrigatório!)

MultiQC: Visão Consolidada

Quando você tem dezenas ou centenas de amostras, FASTQC individual não basta



Combina relatórios de múltiplas amostras em um único **dashboard**



Permite **comparar a qualidade** entre amostras do mesmo experimento



Identifica rapidamente **amostras problemáticas** (outliers)

```
$ multiqc .
```

(Execute na pasta com os relatórios FastQC)

Momento de Reflexão: Qualidade das Bases

Score Q20 = 99% Confiança

Uma base individual com Q20 parece ter uma taxa de erro aceitável de 1%.



O Problema da Escala

Se tivermos 1 milhão de bases com Q20, quantas estarão **ERRADAS**?

Momento de Reflexão: Qualidade das Bases

Score Q20 = 99% Confiança

Uma base individual com Q20 parece ter uma taxa de erro aceitável de 1%.



O Problema da Escala

Se tivermos 1 milhão de bases com Q20, quantas estarão **ERRADAS**?

Resposta: 10.000 bases erradas!

Por isso buscamos o padrão de ouro: Q30+

PARTE 2

Processamento de Dados

Do trim ao denoising: preparando as sequências

Pipeline de Bioinformática: Visão Geral



O Gene 16S rRNA: Nosso Alvo

Gene ribossomal presente em TODOS os procariotos (~1.500 bp), com regiões conservadas e variáveis.



Regiões Conservadas

Permitem desenhar primers universais

Regiões Variáveis

V1-V9: diferenciam as espécies



16S Amplicon

O 'código de barras' dos microrganismos

Regiões Variáveis do 16S

A escolha da região hipervariável é uma decisão experimental

V1-V2

Boa resolução para
Firmicutes e Actinobacteria

V3-V4

Mais utilizada (Illumina
MiSeq, ~460 bp)

V4

Usado pelo Earth
Microbiome Project
(515F/806R)

V5-V6

Alternativa para estudos
marítimos

A escolha da região impacta quais táxons serão detectados!

Não existe 'melhor região' universal: depende do ecossistema

Sequenciamento Paired-End

Cada fragmento de DNA é lido duas vezes: uma da ponta 5' (R1) e outra da ponta 3' (R2).

Reconstrução

O overlap entre R1 e R2 permite reconstruir o amplicon completo



Maior Confiança

Bases no overlap são verificadas duas vezes durante a leitura



Amplicons Longos

Essencial para sequências >150 bp
(ex: V3-V4 ~460 bp)

A técnica paired-end é o padrão ouro para estudos de diversidade microbiana.

Trimming: Removendo o Ruído

Processo de remoção de bases de baixa qualidade e sequências indesejadas das extremidades dos reads.



Qualidade das Bases

Bases na extremidade 3' tendem a apresentar uma qualidade estatística menor.



Remoção de Primers

Devem ser removidos pois não fazem parte da sequência biológica original do organismo.



Contaminantes

Adaptadores de sequenciamento são considerados contaminantes técnicos do processo.

O trimming é fundamental para garantir a acurácia das análises de bioinformática a jusante.

Tipos de Trimming



Quality Trimming

Remove bases com Q abaixo do limiar (ex: Q20).

Usa janela deslizante (sliding window) para avaliar a qualidade.



Adapter Trimming

Remove sequências de adaptadores Illumina.

Cutadapt e Trimmomatic são as ferramentas mais usadas.



Primer Trimming

Remove os primers de PCR.

Cutadapt com as sequências dos primers forward e reverse.

Exemplo: trimming com cutadapt

```
cutadapt \  
  -a ADAPTER_FWD \  
  -A ADAPTER_REV \  
  -q 20 \  
  --minimum-length 100 \  
  -o trimmed_R1.fastq.gz \  
  -p trimmed_R2.fastq.gz \  
  raw_R1.fastq.gz raw_R2.fastq.gz
```

Filtragem: Critérios de Descarte



Comprimento Mínimo

Reads muito curtos são ambíguos e podem gerar falsos positivos no alinhamento.



Max Expected Errors (maxEE)

Soma acumulada de probabilidades de erro. **Ex:** **maxEE=2** descarta reads com >2 erros esperados.



Remoção de 'N'

Bases ambíguas (N) prejudicam a análise e são frequentemente indícios de baixa qualidade.



PhiX Removal

Filtra reads provenientes do controle interno Illumina para evitar contaminação da amostra.

Operational Taxonomic Unit (OTU)

Agrupa sequências com **$\geq 97\%$ de similaridade** em 'clusters'.

Contexto Histórico

- Surgiu na era pré-NGS para lidar com erros de Sanger.
- O limiar de 97% é uma aproximação grosseira do conceito biológico de 'espécie'.

Limitações Críticas

- Altamente dependente do banco de dados e do algoritmo de clustering.
- **Resultados NÃO são reprodutíveis entre estudos diferentes.**

ASV: A Abordagem Moderna

Amplicon Sequence Variant (ASV)

Identifica a sequência **EXATA** após correção de erros do sequenciador.



Resolução Máxima

Diferenciação de 1 único nucleotídeo, oferecendo precisão superior a OTUs.



Alta Reprodutibilidade

A mesma sequência resulta na mesma ASV independentemente do estudo.



Comparabilidade Direta

Permite comparação direta entre diferentes experimentos e laboratórios.



Padrão de Ouro

Atual recomendação consensual da comunidade científica global.

OTU vs. ASV

Critério	OTU (Clustering)	ASV (Denoising)
Resolução	~97% similaridade	Nucleotídeo único
Reprodutibilidade	Depende do dataset	Completamente reprodutível
Comparabilidade	Não entre estudos	Sim, entre estudos
Sequências	Centroide do cluster	Sequência biológica real
Ferramentas	VSEARCH, CD-HIT	DADA2, Deblur, UNOISE3

DADA2: O Algoritmo de Denoising

Divisive Amplicon Denoising Algorithm 2

Modelo estatístico que 'aprende' o perfil de erros do sequenciador.



Analisa as transições de erro ($A \rightarrow C$, $G \rightarrow T$, etc.) para cada score de qualidade



Distingue erros de sequenciamento de variação biológica real



Integrado ao QIIME2 e disponível como pacote R no Bioconductor

Etapas do Processo:

- **1. Aprendizado:** Analisa milhares de reads para calcular taxas de erro por score Q.
- **2. Dereplicação:** Agrupa reads idênticos para eficiência computacional.
- **3. Inferência:** Distingue sequências reais de erros usando o modelo.
- **4. Merging:** Combina R1 e R2 pelo overlap (paired-end).
- **5. Quimeras:** Detecta e remove sequências híbridas artificiais.

DADA2 no R

```
library(dada2)

# 1. Aprender o perfil de erros
errF <- learnErrors(filtFs, multithread=TRUE)

# 2. Inferir ASVs
dadaFs <- dada(filtFs, err=errF, multithread=TRUE)

# 3. Tabela de ASVs
seqtab <- makeSequenceTable(dadaFs)
```

O que são quimeras?

Sequências artificiais criadas durante a PCR, onde fragmentos de dois organismos diferentes se fundem em uma única molécula.

CAUSAS E IMPACTO

- Fragmento incompleto serve de primer para outro template.
- Podem representar **5-30%** das leituras em amplicons!
- Se não removidas, criam '**organismos fantasma**' na análise.

MÉTODOS DE DETECÇÃO

DADA2: Método Bimera

Verifica se uma ASV é a fusão de duas mais abundantes (ASV 'A' + ASV 'B').

VSEARCH: uchime_denovo

Algoritmo alternativo clássico para remoção.

Correspondência perfeita = Quimera!

Removendo Quimeras no DADA2

```
# Remover quimeras biméricas
seqtab.nochim <- removeBimeraDenovo(
  seqtab,
  method = 'consensus',
  multithread = TRUE
)

# Verificar proporção removida
1 - sum(seqtab.nochim)/sum(seqtab) # ex: 0.08 = 8%
```




Uma remoção de **5-15%** é comum. Acima de **30%** pode indicar problema na PCR.

Tracking: quantas reads sobreviveram?

A cada etapa do pipeline, perdemos reads (e isso é esperado!). É crucial registrar quantas passam por cada filtro.

Exemplo de Tracking Table



*Non-chimeric reads (etapa final de limpeza)



Perda total: **30%** (aceitável para a maioria dos estudos).

Se um aluno usa OTUs e outro usa ASVs para analisar a MESMA amostra, eles chegarão nos mesmos resultados?

Por quê?

PARTE 3

Classificação taxonômica

Atribuindo identidade com o banco de dados SILVA

O processo de atribuir uma identidade biológica (Reino → Filo → ... → Gênero → Espécie) a cada ASV obtida.

- É o momento em que passamos de 'sequência X' para 'Lactobacillus acidophilus'
- Depende fundamentalmente de um banco de dados de referência curado
- Nem sempre é possível classificar até espécie (resolução do 16S)

Níveis taxonômicos

Do mais amplo ao mais específico: cada nível requer mais informação

- **Domínio:** Bacteria, Archaea
- **Filo:** Ex: Firmicutes, Proteobacteria, Bacteroidota
- **Classe:** Ex: Bacilli, Gammaproteobacteria
- **Ordem:** Ex: Lactobacillales, Enterobacterales
- **Família:** Ex: Lactobacillaceae, Enterobacteriaceae
- **Gênero:** Ex: Lactobacillus, Escherichia
- **Espécie:** Ex: L. acidophilus, E. coli

Banco de dados de referência para 16S

Coleções curadas de sequências de 16S rRNA com taxonomia atribuída por especialistas.

- São a 'enciclopédia' contra a qual comparamos nossas sequências desconhecidas
- A qualidade da classificação depende diretamente da qualidade do banco
- Diferentes bancos podem produzir resultados ligeiramente diferentes

Banco de dados de referência para 16S

Banco	Nº Sequências	Taxonomia	Atualização
SILVA	~2 milhões	Própria (curada manualmente)	Regular (v138.2)
Greengenes2	~300 mil	Baseada em genomas completos	2022
RDP	~3 milhões	Bergey's Manual	Descontinuado
NCBI/GenBank	>20 milhões	Submissão dos autores	Contínua

SILVA: por que é o padrão?

O SILVA é o banco de dados mais utilizado para análise de 16S por sua curadoria rigorosa e taxonomia consistente.

- Curadoria semiautomática + revisão manual
- Alinhamento de referência pré-computado (SILVA ACT)
- Árvore filogenética de referência incluída
- Atualizações regulares acompanhando a literatura

Versões e arquivos do SILVA

- **SILVA SSU NR99: Não-redundante a 99% (recomendado para classificação)**
- Remove redundância mantendo a diversidade taxonômica
- **SILVA SSU Full: Todas as sequências (para usos especiais)**
- Maior cobertura, mas também mais ruído
- **Arquivos para download:**
- `silva_nr99_v138.2_train_set.fa.gz` (sequências + taxonomia)
- `silva_species_assignment_v138.2.fa.gz` (atribuição em nível de espécie)

Métodos de classificação: uma visão geral

Existem diferentes algoritmos para 'perguntar ao banco' a identidade de uma sequência.

- Cada método tem vantagens e limitações
- A escolha do método pode impactar os resultados
- Importante: nenhum método é 100% preciso

Classificador Naive Bayes (QIIME2)

- **Como funciona:**
 - 1. Treinamento: 'aprende' os padrões de k-mers (subsequências de tamanho k) de cada táxon
 - 2. Classificação: para uma ASV desconhecida, calcula a probabilidade de pertencer a cada táxon
 - 3. Atribuição: escolhe o táxon com maior probabilidade posterior (Bayes)
- **Vantagem: Rápido e robusto para amplicons específicos (V3-V4)**
- **Limitação: Precisa ser treinado para a região específica sequenciada**

O que são k-mers?

**Subsequências de tamanho fixo k , extraídas de uma sequência maior.
São a 'impressão digital' molecular.**

- Sequência: ATCGATCG $\rightarrow$ k-mers de tamanho 3: ATC, TCG, CGA, GAT, ATC, TCG
- Cada organismo tem uma distribuição característica de k-mers
- O classificador compara a distribuição de k-mers da ASV com as referências

Classificador por alinhamento (VSEARCH/BLAST)

- **Como funciona:**
 - 1. Alinha cada ASV contra todas as sequências do banco de dados
 - 2. Usa o melhor hit (ou consenso dos N melhores) para atribuir taxonomia
 - 3. Pode usar alinhamento global (VSEARCH) ou local (BLAST)
- **Vantagem: Mais intuitivo, baseado em similaridade direta**
- **Limitação: Mais lento e pode dar resultados incompletos em baixa similaridade**

Confiança na classificação (bootstrap)

Cada nível taxonômico recebe um score de confiança (0 a 1). Valores abaixo do limiar são marcados como 'não classificado'.

- Confiança ≥ 0.80 (80%): limiar padrão recomendado
- Gêneros frequentemente classificáveis, espécies raramente (com 16S V3-V4)
- Uma ASV 'não classificada' não é um erro: significa que o banco não tem referência suficiente

Exemplo de saída taxonômica

```
ASV_001: k__Bacteria; p__Firmicutes; c__Bacilli;  
         o__Lactobacillales; f__Lactobacillaceae;  
         g__Lactobacillus; s__acidophilus  
         (confiança: 0.99)
```

```
ASV_042: k__Bacteria; p__Proteobacteria;  
         c__Gammaproteobacteria; o__Unclassified  
         (confiança no nível de ordem: 0.52 < 0.80)
```

Classificação no DADA2 (R)

```
# Classificação taxonômica com Naive Bayes
taxa <- assignTaxonomy(
  seqtab.nochim,
  'silva_nr99_v138.2_train_set.fa.gz',
  multithread = TRUE,
  minBoot = 80 # limiar de confiança
)

# Atribuição em nível de espécie (match exato)
taxa <- addSpecies(taxa, 'silva_species_assignment_v138.2.fa.gz')
```

Classificação no QIIME (R)

```
# 1. Treinar o classificador (uma vez)
qiime feature-classifier fit-classifier-naive-bayes \
  --i-reference-reads silva-seqs.qza \
  --i-reference-taxonomy silva-tax.qza \
  --o-classifier silva-classifier.qza

# 2. Classificar as ASVs
qiime feature-classifier classify-sklearn \
  --i-reads rep-seqs.qza \
  --i-classifier silva-classifier.qza \
  --o-classification taxonomy.qza
```


Resultado final: tabela de abundância

Uma matriz de ASVs × Amostras com a contagem de reads, associada a uma tabela taxonômica.

- Cada linha = uma ASV (com sua taxonomia atribuída)
- Cada coluna = uma amostra do estudo
- Cada célula = nº de reads daquela ASV naquela amostra
- Base para todas as análises ecológicas subsequentes

Se uma ASV não é classificada em nível de gênero, isso significa que o organismo não existe? Ou que simplesmente não temos referência para ele?

Alinhar = encontrar a melhor correspondência posicional entre duas ou mais sequências de nucleotídeos/aminoácidos.

- É um dos conceitos mais fundamentais da bioinformática
- Pode ser local (regiões específicas) ou global (sequência inteira)
- Base para mapeamento, filogenia, descoberta de variantes

No 16S, não temos UM genoma de referência. Temos milhões de referências de milhares de espécies.

- O objetivo não é saber 'onde' no genoma, mas 'de quem' é a sequência
- Mapear implica localização → Classificar implica identificação
- São perguntas fundamentalmente diferentes!

ALINHAMENTO / MAPPING

Pergunta: ONDE está esta sequência?

Referência: 1 genoma

Resultado: Coordenada genômica

Ferramentas: BWA, Bowtie2

Aplicações: RNA-seq, Variant Calling, WGS

CLASSIFICAÇÃO TAXONÔMICA

Pergunta: DE QUEM é esta sequência?

Referência: Banco multiespécies (SILVA)

Resultado: Linhagem taxonômica

Ferramentas: Naive Bayes, VSEARCH

Aplicações: Metagenômica 16S, ITS

Alinhamento Genômico = Procurar um livro na biblioteca

Você sabe que o livro existe, quer saber em qual prateleira (posição) ele está.

Classificação Taxonômica = Identificar um animal em uma enciclopédia

Você encontrou um animal e quer saber o que ele é. Compara características com as descrições de milhares de espécies.

Resumo: Etapas para Obter a Sequência de Interesse

Da amostra biológica à sequência limpa e confiável



1. Sequenciamento

DNA → FASTQ (dados brutos)



2. QC

Avaliar qualidade com
FastQC/MultiQC



3. Trimming

Remover primers, adaptadores e
bases ruins



4. Filtragem

Descartar reads abaixo dos
padrões



5. Denoising

Corrigir erros → gerar ASVs



6. Remoção de quimeras

Eliminar artefatos de PCR

Resumo: Etapas para Identificação no Banco de Dados

Da sequência limpa à identidade biológica



1. Escolha do banco

SILVA NR99 v138.2 (16S rRNA)



2. Treinamento

Treinamento do classificador ou uso de modelo pré-treinado



3. Classificação

Naive Bayes ou alinhamento direto contra o banco



4. Filtragem por confiança

Limiar de bootstrap $\geq 80\%$



5. Resultado

Tabela de ASVs $\times$ Amostras com taxonomia atribuída



6. Análise downstream

Diversidade, composição e testes estatísticos



FASTQ Bruto (R1 + R2)

Dados do sequenciador



FastQC / MultiQC

Avaliação de qualidade



Cutadapt / Trimmomatic

Trimming + Filtragem



DADA2 learnErrors()

Modelo de erros



DADA2 dada()

Denoising → ASVs



removeBimeraDenovo()

Remoção de quimeras



assignTaxonomy() + SILVA

Classificação taxonômica



Tabela de Abundância + Taxonomia

Resultado final

- **Diversidade Alfa: Riqueza e equitabilidade dentro de cada amostra**
- Índices: Shannon, Simpson, Chao1, Observed ASVs
- **Diversidade Beta: Diferenças entre amostras**
- Métricas: Bray-Curtis, UniFrac (ponderado e não-ponderado)
- **Composição: Barplots taxonômicos por grupo experimental**
- **Estatística: Testes de hipótese (PERMANOVA, Kruskal-Wallis)**

- Callahan et al. (2016) - DADA2: High-resolution sample inference. Nature Methods
- Quast et al. (2013) - The SILVA ribosomal RNA gene database project. Nucleic Acids Res.
- Bolyen et al. (2019) - QIIME 2: Reproducible, interactive analysis. Nature Biotechnology
- Caporaso et al. (2011) - Global patterns of 16S rRNA diversity. PNAS
- Knight et al. (2018) - Best practices for analysing microbiomes. Nature Reviews

